

# UE Probabilités et statistique 1

Ensimag 1A – Examen blanc

Corrigé

Décembre 2025 – Durée 1h

**Consignes importantes :**

- Ce document **Rmd** constitue votre document de travail. Le devoir doit être **rendu au format PDF**, après avoir complété les espaces réservés aux sections **Réponse**.
  - Il est **fortement conseillé** de compiler (**Knit**) le document régulièrement afin de vérifier l'absence d'erreurs.
  - Pour valider une **Question** comportant un code R à compléter, il est nécessaire de **modifier l'instruction eval = FALSE** en **eval = TRUE** ou de la supprimer.
  - Les réponses attendues devront être clairement rédigées, si possible **en gras**, et ne pas être limitées aux codes informatiques à compléter.
- 

## Énoncé

On dispose d'un jeu de données **x** contenant les résultats de **n = 94** épreuves d'un jeu de pile ("P") ou face ("F"). Le jeu de données est chargé en mémoire de la manière suivante :

```
# charge le jeu de données
x <- scan(file = "pile_ou_face.txt", what = character())
head(x)

## [1] "F"  "P"  "P"  "P"  "F"  "P"
```

### Question 1

À l'aide de commandes R, calculer le nombre de faces ("F") et de piles ("P") dans le jeu de données. Représenter les effectifs observés à l'aide d'un diagramme en barres.

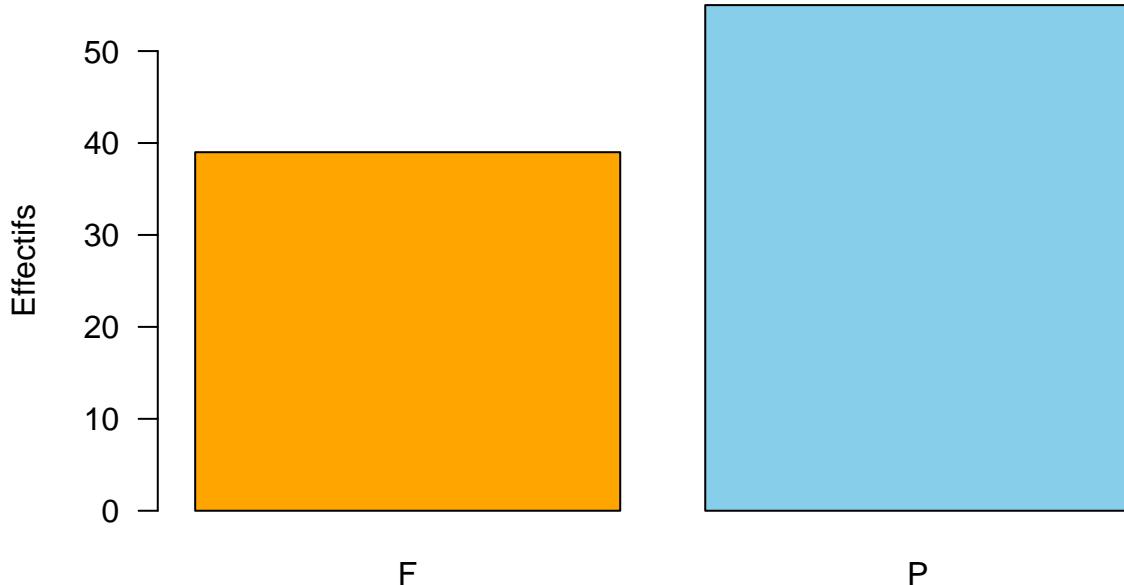
**Réponse.** Compléter les codes suivants et décrire brièvement les résultats obtenus.

```
# effectifs : nombre de "F" et de "P"
effectifs <- table(x)
effectifs

## x
## F   P
## 39 55

# diagramme en barre
barplot(effectifs,
        col = c("orange", "skyblue"),
        las = 1,
        ylab = "Effectifs",
        main = "Résultats du jeu de pile ou face")
```

## Résultats du jeu de pile ou face



On observe 55 piles et 39 faces sur 94 lancers. La proportion de piles (0,59) semble légèrement supérieure à celle attendue pour une pièce équilibrée (0,5).

### Question 2

On suppose que le jeu n'est pas truqué, c'est-à-dire que la probabilité d'obtenir "F" est  $p_0 = 1/2$ . Pour chaque épreuve  $i$ , on définit la variable aléatoire  $X_i$  indiquant la réalisation de l'événement "obtenir F" :

$$X_i = \begin{cases} 1 & \text{si le résultat est F} \\ 0 & \text{sinon.} \end{cases}$$

Les épreuves sont supposées indépendantes. Justifier que la loi de la statistique

$$Z = \frac{1}{\sqrt{n}} \left( 2 \sum_{i=1}^n X_i - n \right)$$

peut être approchée par la loi normale  $\mathcal{N}(0, 1)$ .

### Réponse.

On commence par calculer la moyenne et la variance de  $Z$ . On pose  $S_n = \sum_{i=1}^n X_i$ . On a

$$\mathbb{E}[Z] = \frac{2}{\sqrt{n}} \left( \mathbb{E}[S_n] - \frac{n}{2} \right) = 0,$$

et

$$\text{Var}(Z) = \left( \frac{2}{\sqrt{n}} \right)^2 \text{Var}(S_n) = \frac{4}{n} \times \frac{n}{4} = 1.$$

### Justification de l'approximation normale :

Les conditions du TCL sont triviales ici (variance finie). La variable  $Z$  est une version centrée et réduite d'une somme de variables de Bernoulli identiques indépendantes de variance  $1/4$ .

Nous avons

$$Z = \frac{S_n - n/2}{\sqrt{n/4}}.$$

Par le **théorème central limite**, la loi de  $Z$  est approchée par  $\mathcal{N}(0, 1)$ .

### Question 3

À partir des données observées, calculer la **valeur observée** de la statistique

$$z = \frac{1}{\sqrt{n}} \left( 2 \sum_{i=1}^n x_i - n \right),$$

ainsi que la valeur correspondante  $z^2$ . (On rappelle que  $x_i = 1$  si le résultat est “F” et  $x_i = 0$  sinon.)

**Réponse.** Inclure un code R pour calculer les valeurs demandées arrondies à 4 décimales et décrire brièvement les résultats obtenus.

```
n <- length(x)

# Calcul de z et z^2
z <- (1 / sqrt(n)) * (2 * sum(x == "F") - n)
z2 <- z^2

res <-c(z, z2)
names(res) <- c("z", "z-squared")
round(res,4)

##           z z-squared
##     -1.6503    2.7234
```

La valeur observée  $z$  est environ égale à -1,6503 et la valeur observée  $z^2$  est environ égale à 2,7234.

### Question 4

On suppose que la statistique  $Z$  suit la loi normale standard  $\mathcal{N}(0, 1)$ . À partir de la valeur observée  $z$  obtenue à la [Question 3](#), calculer numériquement à l'aide de R la probabilité

$$P = \mathbb{P}(|Z| > |z|).$$

**Réponse.** Utiliser la fonction `pnorm` pour calculer cette probabilité (arrondir à 4 décimales) et décrire brièvement le résultat obtenu.

```
# Probabilité bilatérale : P(|Z| > |z|)
P <- 2 * pnorm(abs(z), lower = FALSE)
round(P, 4)

## [1] 0.0989
```

La valeur de la probabilité  $P$  est environ égale à 0,0989.

### Question 5

Interprétez la valeur de  $P$  obtenue à la [Question 4](#) dans le cadre d'un test d'hypothèse sur la probabilité d'obtenir “Face”. Précisez :

- l'hypothèse nulle et l'hypothèse alternative testées,
- la décision que vous prenez au seuil de 5 %.

### Réponse.

La probabilité  $P$  correspond à la  $p$ -valeur du test d'hypothèse

$$H_0 : p = 0,5 \quad (\text{le jeu est équilibré}) \quad H_1 : p \neq 0,5 \quad (\text{le jeu est truqué}).$$

La  $p$ -valeur obtenue à la [Question 4](#) est  $P \approx 0,10$ . Comme  $P > 0,05$ , on ne rejette pas l'hypothèse nulle au seuil de 5 %. Les données ne permettent donc pas de conclure que le jeu est truqué.

### Question 6

Calculer la  $p$ -valeur du test de l'hypothèse nulle “le jeu est équilibré” contre l'hypothèse alternative “le jeu est truqué” à l'aide de la commande R `prop.test`. Comparer le résultat à celui obtenu précédemment et préciser quelle loi statistique est utilisée pour le calcul du test.

**Réponse.** Compléter et exécuter le code suivant.

```
# Modifier eval = FALSE en eval = TRUE
# Test de proportion sans correction de continuité
test_trucage <- prop.test(x = 39,      # nombre de "F"
                           n = 94,      # nombre total d'épreuves
                           p = 0.5,      # hypothèse nulle : jeu équilibré
                           correct = FALSE)

test_trucage

## 
## 1-sample proportions test without continuity correction
##
## data: 39 out of 94, null probability 0.5
## X-squared = 2.7234, df = 1, p-value = 0.09889
## alternative hypothesis: true p is not equal to 0.5
## 95 percent confidence interval:
## 0.3205503 0.5159198
## sample estimates:
##          p
## 0.4148936
```

La  $p$ -valeur est identique à la valeur  $P$  calculée dans la [Question 5](#). Cela suggère que `prop.test` applique une approximation gaussienne pour calculer la  $p$ -valeur.

### Question 7

À quoi correspond la statistique `X-squared = 2.7234` affichée dans la sortie de la commande `prop.test`? Le test effectué à la [Question 6](#) est-il équivalent au test réalisé à la [Question 5](#)?

**Réponse.** Justifiez brièvement votre réponse à l'aide d'un argument de probabilité.

La statistique `X-squared = 2.7234` correspond à la valeur  $z^2$  calculée dans la [Question 3](#). Ce test est équivalent à celui réalisé à la [Question 5](#) car

$$P = \mathbb{P}(|Z| > |z|) = \mathbb{P}(Z^2 > z^2).$$

En conclusion, le test de proportion `prop.test` repose sur la même approximation normale, simplement exprimée sous forme de  $Z^2$  (ou  $\chi^2$ ) plutôt que de  $Z$ .

## Question 8

Déterminer, à l'aide de R, un intervalle de confiance à 95 % pour la fréquence de “Face” (“F”) observée dans les données (arrondir à 4 décimales). Indiquer la commande utilisée et interpréter brièvement le résultat.

### Réponse.

On extrait `conf.int` de l'objet créé par la commande précédente.

```
# Intervalle de niveau de confiance 95%
round(test_trucage$conf.int, 4)
```

```
## [1] 0.3206 0.5159
## attr(),"conf.level")
## [1] 0.95
```

On remarque que la valeur 0,5 se trouve dans la plage des valeurs compatibles avec l'hypothèse nulle. On ne rejette pas l'hypothèse que le jeu est équilibré.

## Question 9

Sous l'hypothèse d'un jeu équilibré, calculer les effectifs attendus de “F” et de “P” pour  $n = 94$  observations. On note  $E_F$  et  $E_P$  les effectifs attendus et  $O_F$  et  $O_P$  les effectifs observés. Calculer la statistique du Chi-deux

$$\chi^2 = \frac{(E_F - O_F)^2}{E_F} + \frac{(E_P - O_P)^2}{E_P}.$$

À l'aide d'une commande R, effectuer un test du Chi-deux et calculer la  $p$ -valeur. Commenter le résultat obtenu.

### Réponse.

```
# Modifier eval = FALSE en eval = TRUE
# effectifs attendus
n <- length(x)
E <- c(F = n * 0.5, P = n * 0.5)

# effectifs observés
O <- table(x)

# statistique du Chi-deux
chi2 <- sum((E - O)^2 / E)
chi2
```

```
## [1] 2.723404
```

La statistique du Chi-deux est égale à 2,7234. On retrouve la valeur calculée dans les questions précédentes ( $z^2$  ou X-squared).

```
# Test du Chi-deux
chisq.test(table(x), p = c(0.5, 0.5))
```

```
##
##  Chi-squared test for given probabilities
##
##  data:  table(x)
##  X-squared = 2.7234, df = 1, p-value = 0.09889
```

Le test est équivalent à celui effectué Question 7. Il repose sur une approximation gaussienne. Au seuil de 5 %, les données ne fournissent pas de preuve suffisante que le jeu soit truqué.

### Question 10

On révèle que le jeu de données provient en réalité de la simulation suivante :

```
set.seed(2025)
x_sim <- sample(c("F", "P"), 94, prob = c(0.40, 0.60), replace = TRUE)

# verification
identical(x, x_sim)

## [1] TRUE
```

Sachant que la probabilité réelle d'obtenir “F” est  $p = 0,40$ , que peut-on conclure sur les valeurs de significativité ( $p$ -valeurs) obtenues dans les [Questions](#) précédentes ? Commentez brièvement la validité de l'analyse statistique.

**Réponse.** Les tests précédents reposaient sur l'hypothèse nulle ( $H_0 : p = 0,5$ ). Les  $p$ -valeurs obtenues (10 %) étaient supérieures au seuil de 5 %, ce qui nous a conduit à ne pas rejeter ( $H_0$ ). En réalité, les données proviennent d'une loi où  $p = 0,4$  : le jeu est donc effectivement légèrement biaisé en faveur de “P”. Cela montre que, malgré un biais réel, la taille de l'échantillon ( $n = 94$ ) est trop faible pour détecter ce biais au seuil de 5 %. On a commis ici une erreur de type “ne pas rejeter une hypothèse fausse”.